



# 基于深度学习的复杂模拟电路故障识别

黄泽华<sup>1,2</sup> 毕贵红<sup>1</sup> 张梓睿<sup>1</sup>

(1. 昆明理工大学 电力工程学院, 云南 昆明 650500; 2. 永州市工业贸易中等专业学校, 湖南 永州 425300)

**摘要** 复杂的模拟电路故障传递关系复杂, 故障类型与故障特征之间存在复杂的非线性关系, 导致特征提取困难和故障识别困难。针对该问题, 文中提出了一种两测点、自适应噪声完备集合经验模态分解(Complete Ensemble Empirical Mode Decomposition with Adaptive Noise, CEEMDAN) – 多尺度伪彩色图像 – AlexNet 网络结合的模拟电路故障诊断方法。将复杂模拟电路两测点输出信号前后相接构造新的组合故障样本, 两测点组合故障样本数据提高了表征复杂模拟电路整体故障状态的能力。将组合的故障样本信号进行多尺度分解, 并将多尺度数据矩阵映射为二维伪彩色图, 形成信息丰富、特征明显的多尺度故障伪彩色图像。利用深度学习模型 AlexNet 优异的图像特征挖掘和学习能力, 将不同故障类型的多尺度伪彩色图像输入 AlexNet 中进行模型迁移训练学习并完成故障识别。通过对简单电路和复杂电路的单双故障及混合故障识别的比较分析, 证明了所提模拟电路故障诊断方法对复杂模拟电路的不同故障类型能达到更高的识别准确率。

**关键词** 模拟电路; 故障诊断; 双故障; CEEMDAN; 伪彩色; AlexNet; 低通滤波器; 特征可视化

中图分类号 TN710 文献标识码 A 文章编号 1007-7820(2025)02-023-12

doi: 10.16180/j.cnki.issn1007-7820.2025.02.004

## Fault Identification of Complex Analog Circuit Based on Deep Learning

HUANG Zehua<sup>1,2</sup>, BI Guihong<sup>1</sup>, ZHANG Zirui<sup>1</sup>

(1. Faculty of Electric Power Engineering, Kunming University of Science and Technology, Kunming 650500, China;

2. Yongzhou Industrial Trade Secondary Professional School, Yongzhou 425300, China)

**Abstract** For complex analog circuits with complex fault transfer relationships and complex nonlinear relationships between fault types and fault features, which cause difficulties in feature extraction and fault identification. This study presents a fault diagnosis method for analog circuits based on two measuring points – CEEMDAN(Complete Ensemble Empirical Mode Decomposition with Adaptive Noise) – multi-scale false-color image – ALEXNet network. A new combined fault sample is constructed by connecting the output signals of two measuring points in a complex analog circuit. The combined fault sample data of two measuring points improves the ability to characterize the whole fault state of the complex analog circuit. The combined fault sample signals are decomposed in multi-scale, and the multi-scale data matrix is mapped to a two-dimensional false-color graph to form a multi-scale false-color image with abundant information and obvious features. Based on AlexNet's excellent image feature mining and learning ability, multi-scale false-color images of different fault types were input into AlexNet for model transfer training and fault identification. By comparing and analyzing the single and double faults and mixed faults of simple circuit and complex circuit, it is proved that the proposed method can achieve higher recognition accuracy for different fault types of complex analog circuit.

**Keywords** analog circuit; fault diagnosis; double fault; CEEMDAN; false color; AlexNet; low pass filter; feature-based visualization

数字电路占据了电子电路组成部分的 80% 左右,

但 80% 的故障都来自于模拟电路部分<sup>[1]</sup>。模拟电路对电子设备的稳定性和可靠性具有重要影响, 因此模拟电路故障诊断是工程领域的热门研究内容<sup>[2]</sup>。

由于实际电路功能复杂, 故障的传递关系复杂, 电路中的模拟元器件存在一定容差, 电路存在噪声, 导致不同故障的表现具有一定的相似性, 因此较难精准描述故障与征兆之间的关系, 给故障判别带来较大困难<sup>[3]</sup>。目前, 故障诊断方法主要有基于模型分析法、基于信号处理法以及基于人工智能法 3 类<sup>[4]</sup>。基于人工智能的模拟电路故障识别方法包括传统机器学习方法

收稿日期: 2023-06-19 修回日期: 2023-07-16

基金项目: 云南省科技厅科技计划(202201AT070155)

Science and Technology Plan of Science and Technology Department of Yunnan(202201AT070155)

**作者简介:** 黄泽华(1992-), 男, 硕士研究生。研究方向: 电路与系统、电路故障诊断。毕贵红(1968-), 男, 通信作者, E-mail: km\_bgh@163.com, 博士, 教授。研究方向: 电力系统与智能算法结合相关技术。张梓睿(1998-), 男, 硕士研究生。研究方向: 新能源发电并网。

和深度学习方法两种。

传统机器学习方法包括信号预测处理、特征提取和分类或聚类 3 个步骤。文献[5]使用 S 变换(S-Transform, ST)对信号进行预处理。随后,通过灰度共生矩阵(Gray Level Co-Occurrence Matrix, GLCM)方法提取特征,并采用融合粒子群算法(Particle Swarm Optimization, PSO)和粒子滤波算法(Particle Filter, PF)方法对支持向量机(Support Vector Machine, SVM)<sup>[6]</sup>进行优化分类。文献[7]提出将变分模态分解(Variational Mode Decomposition, VMD)和复合多尺度排列熵(Composite Multi-scale Permutation Entropy, CMPE)相结合的算法来构建故障特征向量,并且依靠麻雀搜索算法优化 SVM 完成故障分类。文献[4]提出一种基于模糊 C 均值聚类(Fuzzy C-Means Algorithm, FCM)-局部线性嵌入(Locally Linear Embedding, LLE)模拟电路故障诊断算法,使用局部线性嵌入法对特征数据进行降维,利用模糊 C 均值聚类方法进行故障分类诊断。传统机器学习方法能够实现模拟电路的高精度分类,但该方法的特征提取依赖于专家经验,提取的特征量缺乏适应性,使模型构建与具体电路相关,难以泛化到其他电路上。传统机器学习能够区分的故障种类有限,难以适应复杂电路故障类别故障特征不明显的情况。

近年来,研究者提出了基于深度学习的模拟电路识别新方法,避免了传统人工选择特征的主观性,利用神经网络的自动学习和特征挖掘能力进行特征提取。这种方法适用于复杂的模拟电路故障识别问题,能够达到较高的准确率。该类方法可分为信号预处理与深度学习与识别两步。信号预处理对信号进行分析实现去噪或者信号变换处理,为深度学习模型提取特征、挖掘规律和分类提供合适的输入样本。深度学习识别阶段主要通过卷积神经网络(Convolutional Neural Networks, CNN)、循环神经网络(Recurrent Neural Network, RNN)等神经网络模拟人类大脑结构和自我训练能力,对大量模拟电路故障样本数据进行学习,实现复杂模拟电路的故障分类<sup>[7-11]</sup>。

目前,基于深度学习的典型复杂模拟电路(例如二级四运放双二阶低通滤波器)故障识别的研究在单元件故障识别方面识别率较高,但对于双元件故障及混合故障的识别较困难<sup>[7]</sup>。模拟电路故障信号既可以直接将一维信号输入深度学习网络,也可以将一维信号通过某种数学变换将其转换为二维图像数据,再结合 CNN 等深度学习模型分类模拟电路故障。在复杂模拟电路故障识别方面,由于将一维信号转换为二维图像能够形成信息充分、特征明显的图像训练集,而 CNN 等深度学习模型对图像特征的提取和规律的挖

掘能力较强,所以二维图像和深度学习结合方法是研究复杂模拟电路故障识别的主要方法。文献[11]对故障信号进行多尺度分解,并将多尺度分量转换为彩色图,有利于提取和识别复杂故障的特征。文献[12]将故障信号的多尺度伪彩色图和 AlexNet 网络结合,提高了复杂配电网故障识别和定位的准确性。

模拟电路故障诊断的最终目标是根据电路节点的输出数据判断该电路是否出现故障以及定位故障元件的位置。模拟电路的测点选择对电路故障诊断具有重要影响。由于电路结构复杂,故障在传播到输出端口时可能变得微弱或消失,无法在电路的输出测点表现出故障,导致输出测点的数据表达故障特征的信息有限<sup>[13]</sup>。若仅从输出端口获取数据进行故障诊断,易导致测点记录的数据无法充分表达故障特征的信息,所以需要合理选择测点位置和数量以提高故障数据表征整个电路故障状态的能力<sup>[14]</sup>。目前,研究者选择最终输出为测点的单测点方式研究复杂模拟电路,限制了深度学习的复杂故障学习和分类能力。

针对复杂模拟电路的故障诊断识别问题,本文提出了一种两测点、CEEMDAN 多尺度伪彩色图像和 AlexNet 网络相结合的模拟电路故障诊断方法。首先通过 SIMetrix-SIMPLIS 8.20 软件进行模拟电路的故障数据采集,利用 CEEMDAN 分解方法将所得信号分解,得到多尺度数据矩阵,再进行量化编码、伪彩色出图获得多尺度伪彩色图,将不同故障的多尺度伪彩色图经压缩成  $227 \times 227 \times 3$  大小送至 AlexNet 卷积神经网络。最后,利用 AlexNet 深度学习网络提取模拟电路故障特征,确定故障的类型,完成模拟电路故障诊断。

## 1 原理方法

### 1.1 自适应完备经验模态分解

CEEMDAN 也称自适应噪声完备集合经验模态分解,是在经验模态分解(Empirical Mode Decomposition, EMD)和集合经验模态分解(Ensemble EMD, EEMD)的基础上提出的改进算法<sup>[15]</sup>。

CEEMDAN 通过向故障输出信号加入有限次的自适应高斯白噪声来辅助分解,以减小重构误差和提高分解效率,有效解决了 EMD 中的模态混叠缺陷以及 EEMD 中计算复杂度高和虚假模态分量(Intrinsic Mode Functions, IMFs)较多的问题<sup>[16]</sup>。

CEEMDAN 分解步骤如下:

步骤 1 将高斯白噪声  $\omega_i(t)$  添加到原故障输出信号  $y(t)$  中,即

$$y_i(t) = y(t) + \varepsilon \omega_i(t) \quad (1)$$

式中  $\varepsilon$  为白噪声的幅值。

步骤2 将添加高斯白噪声后的原始故障输出信号  $y(t)$  进行 EMD 分解得到第一个本征模态分量  $IMF_1$  和残差  $r_1(t)$ , 即

$$IMF_1(t) = \frac{1}{n} \sum_{i=1}^n IMF_{i1}(t) \quad (2)$$

$$r_1(t) = y(t) - IMF_1(t) \quad (3)$$

式中  $n$  为加入白噪声的次数。

步骤3 在残差  $r_1(t)$  中加入白噪声  $\varepsilon_1 E_1(\omega_i(t))$ , 再进行 EMD 分解得到第 2 个模态分量  $IMF_2$  和残差  $r_2(t)$ , 即

$$IMF_2(t) = \frac{1}{n} \sum_{i=1}^n (E_1(r_1(t)) + \varepsilon_1 E_1(\omega_i(t))) \quad (4)$$

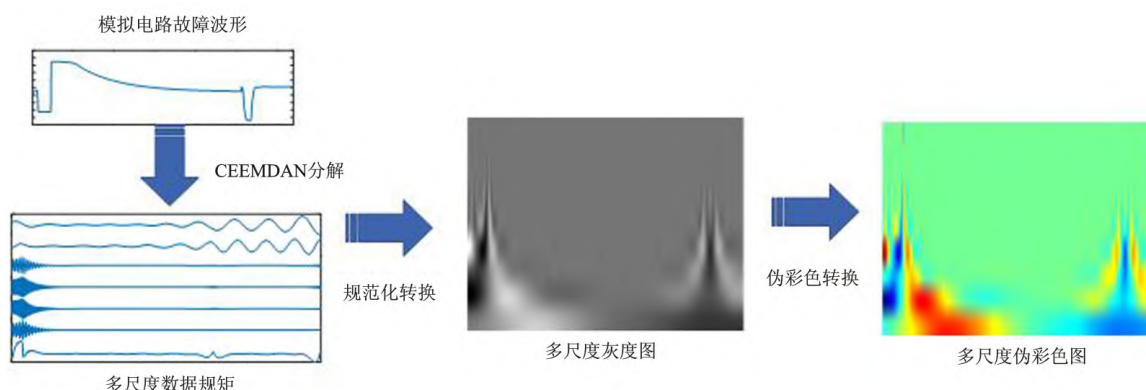


图1 模拟电路故障生成伪彩色图像流程

Figure 1. Pseudo-color image flow generated by analog circuit fault

各种信号分量拼接而成的矩阵是一个典型的实值矩阵, 将实值矩阵中的元素规范化至一定区间内, 具有特定的像素强度, 此时实值矩阵转化为像素矩阵。将像素矩阵的像素值与计算机内部编码的灰度值对应从而绘制出灰度图, 基于此利用伪彩色编码技术可将灰度图像转化为三通道 RGB (Red, Green, Blue) 彩色图。彩色图不仅能够增强图像的隐含特征信息, 也有利于网络的特征识别<sup>[17]</sup>。利用信号-图像转化方法生成特征分量彩色图, 如图1所示。

模拟电路故障信号为一维时序信号, 经 CEEMDAN 分解后得到一系列 IMF 与残差分量, 将这些分量纵向拼接(每一个 IMF 与残差分量均为  $1 \times N$  的行向量序列, 将不同序列按纵向排布)成  $M \times N$  分量矩阵。 $M \times N$  分量矩阵可通过式(7)规范化从而转化为像素矩阵。

$$P(m, n) = \text{round} \left[ \frac{x_i - x_{\min}}{x_{\max} - x_{\min}} \times 255 \right] \quad (7)$$

式中  $P(m, n)$  表示第  $m$  行、第  $n$  列中像素矩阵的像素值;  $x_i$  表示第  $i$  个数据点的值;  $x_{\min}$  与  $x_{\max}$  分别表示

$$r_2(t) = r_1(t) - IMF_2(t) \quad (5)$$

步骤4 重复步骤1~步骤3, 对每一个添加的白噪声分解, 直到得到的残差信号不能够再分解, 则原输出信号  $y(t)$  被分解为式(6)。

$$y(t) = \sum_{j=1}^n IMF_j(t) + r_j(t) \quad (6)$$

## 1.2 故障信号转换成多尺度的彩色图

对模拟电路故障信号利用 CEEMDAN 进行多尺度分解, 获得故障信号的多尺度数据矩阵。对多尺度数据矩阵进行规范化处理, 获得对应的多尺度灰度图像。利用伪彩色编码原理将多尺度灰度图像转换为彩色图像, 如图1所示。

分量矩阵中的最小值与大值。通过式(7)将分量矩阵内数值规范化至(0, 255)内, 使分量矩阵中的值具有一定像素强度。根据各像素值的大小可将其绘制为灰度图, 再利用伪彩色编码可将灰度图转化为特征分量彩色图<sup>[11]</sup>。

## 1.3 AlexNet 卷积神经网络模型

作为卷积神经网络算法的一种, AlexNet 模型是第二代 CNN, 其在前一代 CNN 的基础上加深了网络结果。该网络在图像处理中使用效果较好, 被广泛应用于各领域。

由图2可知, 经典 AlexNet 神经网络模型由5个卷积层、3个池化层、3个全连接层以及1个 Softmax 层构成。5个卷积层采用不同卷积核数量和大小, 分别为 96、256、384、384、256<sup>[18]</sup>。AlexNet 网络模型采用线性整流单元 (Rectified Linear Unit, ReLU) 作为激活函数, 相比 tanh 函数, ReLU 更贴近生物神经元的激活机制, 增强了网络的稀疏性, 提高了模型训练速度, 也解决了梯度消失问题。AlexNet 还引入了具有随机抑制功能的 dropout 技术, 随机抑制某些神经元。将这些神经元的激

活值设为0,以提高模型的泛化能力,并有效减缓过拟合<sup>[12]</sup>。从输入层到卷积层开始,之后的每一层是两个相同结构被分开计算,这是因为该模型将计算内容平均分配给两块GPU(Graphic Processing Unit)。

相较于其他网络,AlexNet模型结构简单、易于训练、计算时间短,对于图像识别具有较强的识别能力,被广泛应用于图像识别、图像检索等领域。

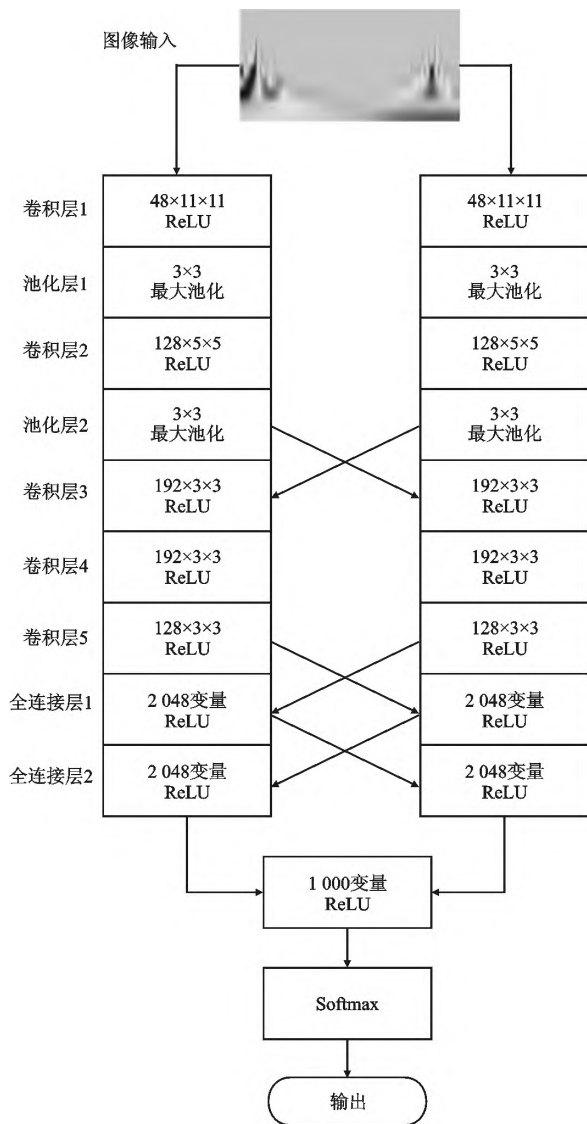


图2 AlexNet 结构

Figure 2. AlexNet structure

## 2 模拟电路故障识别方法步骤

基于 AlexNet 深度学习网络的模拟电路故障诊断方法如图3所示,具体步骤如下所示:

**步骤1** 采集复杂模拟电路故障信号数据作为待分解数据(本文选二级四运放双二阶低通滤波电路作为待测电路)。

**步骤2** 利用 CEEMDAN 分解方法对待分解信号

进行分解,得到多尺度数据矩阵。

**步骤3** 采用量化编码方式对多尺度信号矩阵进行处理,得到对应的像素矩阵。

**步骤4** 使用伪彩色编码对像素矩阵进行编码,生成多尺度伪彩色图,并将所得多尺度伪彩色图进行网格规范化压缩处理,使其满足 AlexNet 网络需要的  $227 \times 227 \times 3$  大小。

**步骤5** 将模拟电路故障信号对应的多尺度伪彩色图输入给 AlexNet 模型进行故障特征学习和识别。

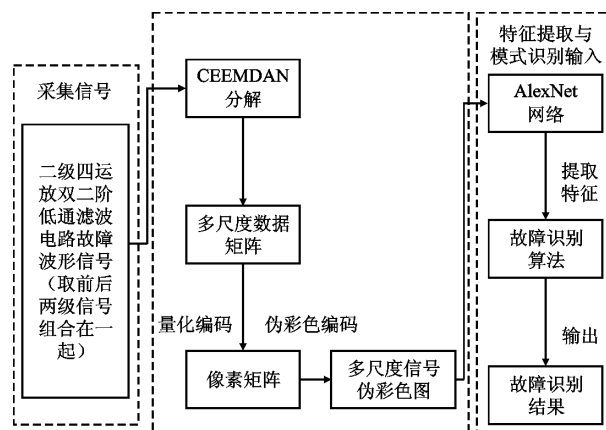


图3 故障检测原理

Figure 3. The fault detection principle

## 3 实验

### 3.1 仿真实验

#### 3.1.1 实验对象

为验证本文诊断方法在复杂模拟电路中故障诊断的能力,选择二级四运放双二阶低通滤波器作为待测电路,如图4所示。采用 SIMetrix - SIMPLIS 8.20 软件进行电路仿真实验,将 MATLAB R2022a 作为特征提取与故障诊断实验平台。

#### 3.1.2 模拟电路故障仿真

1) 故障类型设置:考虑单元件故障和双元件故障,由于电路中元件较多,本文仅选取部分元件(依据各元件敏感度及其在电路中的位置)作为故障元件。单故障包括  $C_1 \uparrow$ 、 $C_2 \uparrow$ 、 $C_3 \downarrow$ 、 $C_4 \uparrow$ 、 $R_1 \uparrow$ 、 $R_7 \downarrow$ 、 $R_{13} \uparrow$ 、 $R_{14} \downarrow$ 、 $R_{16} \downarrow$ 、 $R_{18} \uparrow$ 、 $R_{19} \downarrow$  和正常状态(Normal For, NF)共12种类型,如表1所示。双故障包括( $R_1 \downarrow C_1 \uparrow$ )( $R_1 \downarrow C_4 \downarrow$ )( $R_1 \downarrow R_2 \downarrow$ )( $R_1 \downarrow R_{18} \downarrow$ )( $R_{13} \downarrow C_3 \uparrow$ )等共16种类型,如表2所示。其中, $\uparrow$ 表示电阻和电容值为原标称值的两倍, $\downarrow$ 表示为原标称值的一半。

2) 激励信号:二级四运放双二阶低通滤波器电路的激励信号为单次脉冲激励信号,信号的幅值为5V,信号上升沿为  $1 \mu s$ ,信号下降沿为  $1 \mu s$ ,脉冲宽度为  $10 \mu s$ 。

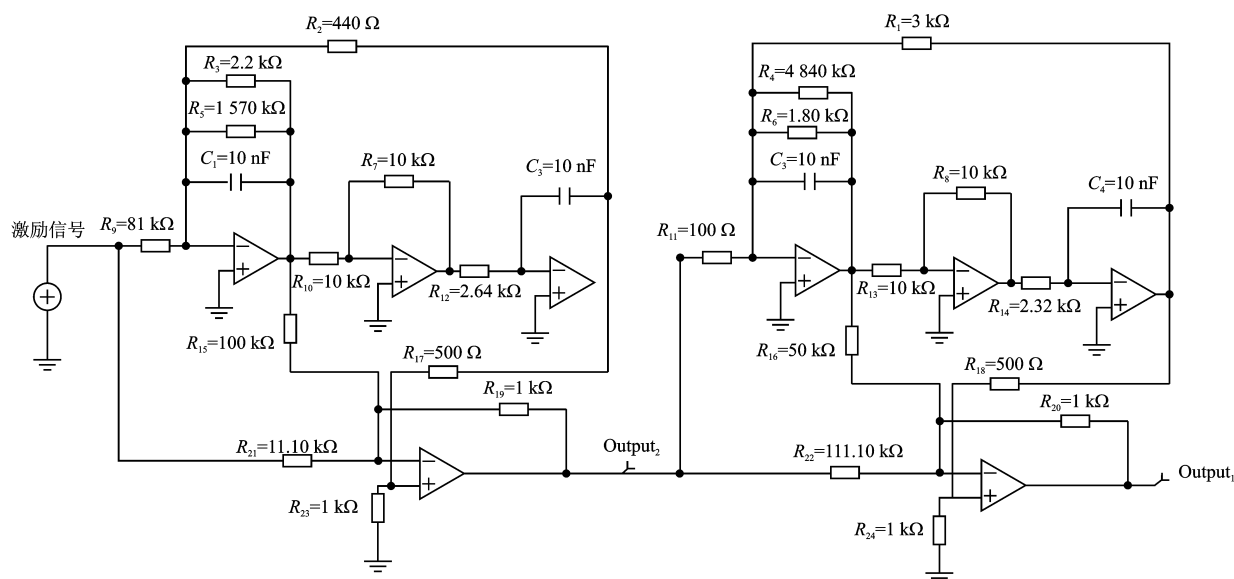


图4 二级四运放双二阶低通滤波电路

Figure 4. Two level four amplifier double level low pass filter circuit

3) 测量点选取: 为研究测量点数对模拟电路故障识别的影响, 本文设置了两个输出测点  $Output_1$  和  $Output_2$ 。

4) 故障信号仿真: 在实际工作环境下, 电路元件受温度、湿度等环境因素干扰, 在标称值范围内存在一定容差, 电路的输出随元件值的容差变化在一定范围内波动。因此为模拟实际工作环境, 取电容的容差率为10%, 电阻的容差率为5%, 对单元件故障和双元件故障采用蒙特卡洛方法进行200次仿真, 每个测点产生对应每个故障的200个样本输出。仿真输出的数据采样频率设置为0.2 MHz, 采样间隔为5  $\mu$ s, 截取信号时间为4.1 ms, 每个样本的样本点数为820个, 双测点每个样本共得到1 640个样本点。单故障组合中各测试元件参数如表1所示, 双故障组合中各测试故障元件参数如表2所示。其中,  $\uparrow$  表示电阻和电容值为原标称值的两倍,  $\downarrow$  表示为原标称值的一半。

表1 单故障组合中各测试元件参数

Table 1. Parameters of each test element in the single fault combination

故障编号	故障类型	元件标称值	容差范围/%	元件故障值
$F_1$	NF			
$F_2$	$C_1 \uparrow$	0.01 nF	10	0.020 nF
$F_3$	$C_2 \uparrow$	0.01 nF	10	0.020 nF
$F_4$	$C_3 \downarrow$	0.01 nF	10	0.005 nF
$F_5$	$C_4 \uparrow$	0.01 nF	10	0.020 nF
$F_6$	$R_1 \uparrow$	1 570.00 k $\Omega$	5	3 140.000 k $\Omega$
$F_7$	$R_7 \downarrow$	2.64 k $\Omega$	5	1.320 k $\Omega$
$F_8$	$R_{13} \uparrow$	1.80 k $\Omega$	5	3.600 k $\Omega$
$F_9$	$R_{14} \downarrow$	4.84 k $\Omega$	5	2.420 k $\Omega$
$F_{10}$	$R_{16} \downarrow$	3.00 k $\Omega$	5	1.500 k $\Omega$
$F_{11}$	$R_{18} \uparrow$	10.00 k $\Omega$	5	20.000 k $\Omega$
$F_{12}$	$R_{19} \downarrow$	10.00 k $\Omega$	5	5.000 k $\Omega$

表2 双故障组合中各测试故障元件的参数

Table 2. Parameters of each test fault component in the double fault combination

故障编号	故障类型	元件标称值	元件故障值
$F_1$	$R_1 \downarrow C_1 \uparrow$	1 570.00 k $\Omega$ 0.01 nF	785.00 k $\Omega$ 0.020 nF
$F_2$	$R_1 \downarrow C_4 \downarrow$	1 570.00 k $\Omega$ 0.01 nF	785.00 k $\Omega$ 0.005 nF
$F_3$	$R_1 \downarrow R_2 \downarrow$	1 570.00 k $\Omega$ 2.20 k $\Omega$	785.00 k $\Omega$ 1.100 k $\Omega$
$F_4$	$R_1 \downarrow R_{18} \downarrow$	1 570.00 k $\Omega$ 10.00 k $\Omega$	785.00 k $\Omega$ 5.000 k $\Omega$
$F_5$	$R_{13} \downarrow C_3 \uparrow$	1.80 k $\Omega$ 0.01 nF	0.90 k $\Omega$ 0.020 nF
$F_6$	$R_{13} \downarrow C_4 \uparrow$	1.80 k $\Omega$ 0.01 nF	0.90 k $\Omega$ 0.020 nF
$F_7$	$R_{13} \downarrow R_{14} \downarrow$	1.80 k $\Omega$ 4.84 k $\Omega$	0.90 k $\Omega$ 2.420 k $\Omega$
$F_8$	$R_{13} \downarrow R_{19} \uparrow$	1.80 k $\Omega$ 10.00 k $\Omega$	0.90 k $\Omega$ 20.000 k $\Omega$
$F_9$	$R_{18} \downarrow C_3 \uparrow$	10.00 k $\Omega$ 0.01 nF	5.00 k $\Omega$ 0.020 nF
$F_{10}$	$R_{18} \downarrow R_7 \uparrow$	10.00 k $\Omega$ 2.64 k $\Omega$	5.00 k $\Omega$ 5.280 k $\Omega$
$F_{11}$	$R_{18} \uparrow C_1 \downarrow$	10.00 k $\Omega$ 0.01 nF	20.00 k $\Omega$ 0.005 nF
$F_{12}$	$R_{18} \uparrow C_2 \uparrow$	10.00 k $\Omega$ 0.01 nF	20.00 k $\Omega$ 0.020 nF
$F_{13}$	$C_2 \uparrow C_3 \downarrow$	0.01 nF 0.01 nF	0.02 nF 0.005 nF
$F_{14}$	$C_2 \uparrow C_4 \downarrow$	0.01 nF 0.01 nF	0.02 nF 0.005 nF
$F_{15}$	$C_2 \uparrow R_{16} \downarrow$	0.01 nF 3.00 k $\Omega$	0.02 nF 1.500 k $\Omega$
$F_{16}$	$C_2 \uparrow R_{20} \uparrow$	0.01 nF 2.32 k $\Omega$	0.02 nF 4.640 k $\Omega$

## 3.2 故障特征图生成


### 3.2.1 两个测量点故障波形图生成

二级四运放双二阶低通滤波器取两个测量点, 每个测量点共820个样本数据, 取  $Output_1$  前800个样本数据和  $Output_2$  前200点样本数据放大10倍(放大10倍后数据的电压波形特征未改变), 并将两测点组合为1 000个样本点。记二级四运放双二阶低通滤波电路的故障样本测点  $Output_1$  为  $y_1(n)$   $n = 1, \dots, N$   $N = 800$ ,  $Output_2$  为  $y_2(m)$   $m = 1, \dots, M$   $M = 200$ 。  $y(n)$  为组合后的两侧点故障样本数据, 如式(8)所示。


$$y(k) = \{y_1(n), 10 \times y_2(m)\} \quad k = 1, 2, 3, \dots, 1000 \quad (8)$$



因为各故障元件的敏感度不同,导致各个元件参数发生故障的波形不同,两个测点组合前后 800 点和后 200 点的信号分别体现两段不同波形的信号特征,图 5 为典型的双测点故障类型,图 5 (a) 为单故障波



(a)



(b)

图 5 二级四运放双二阶低通滤波电路典型故障输出波形


(a) 单故障输出波形 (b) 双故障输出波形

Figure 5. Typical fault output waveforms of two-level quad-amp two-level low-pass filter circuit

(a) Single fault output waveforms (b) Double fault output waveforms

### 3.2.2 CEEMDAN 多尺度特征图和多尺度伪彩色图

二级四运放双二阶低通滤波器的故障类型输出波形信号经过 CEEMDAN 分解后得到多尺度数据矩阵,图 6 为“ $C_2$ 上升”故障数据经 CEEMDAN 分解后的故障类型模态分量。故障信号分解后得到了不同的 IMF<sub>s</sub> 模态分量图,共 10 个分量,分别从高频到低频排列。

图 6 “ $C_2$ 上升”故障类型分解结果Figure 6.  $C_2$  ascending fault type resolution result

将模拟电路故障特征信号经 CEEMDAN 分解后得到多尺度数据矩阵,多尺度数据矩阵经量化编码后得到像素矩阵,再利用伪彩色编码将像素矩阵编码得到多尺度伪彩色图。28 种故障类型将得到 28 种多尺度伪彩色图,按故障类型的组合分为单故障、双故障。单故障为 12 种(包含了 NF“正常”情况),双故障为 16 种。图 7 为 6 种典型故障类型的多尺度信号伪彩色图,每张图均有两个陡峭区域,两个陡峭区域分别对应两个测点的波形振荡区间。多尺度伪彩色图之间的特征区别为后续 AlexNet 卷积神经网络的深层次特征提取和识别提供了基础。

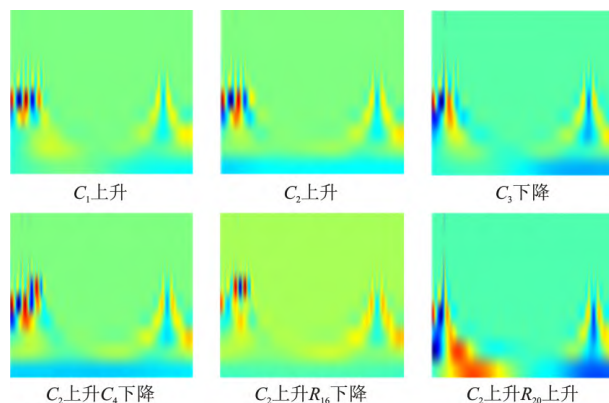


图 7 6 种故障类型多尺度伪彩色图

Figure 7. Multi-scale false-color diagram of six fault types

### 3.3 基于 AlexNet 的二级四运放双二阶低通滤波器故障识别实验

#### 3.3.1 AlexNet 模型迁移与学习

利用深度学习模型 AlexNet 良好的图像特征挖掘和学习能力的特点进行复杂模拟电路故障识别分类。以二级四运放双二阶低通滤波器为对象, 针对被测电路每种故障进行 200 次蒙特卡洛方法分析, 生成的 200 个参数样本对应产生 200 张多尺度伪彩色图。随机选取 175 张为训练样本, 25 张为测试样本, 将训练样本和测试样本送入预训练好的 AlexNet 模型做迁移学习。整个电路

故障分为单故障、双故障、单双混合故障 3 种组合, 每种组合故障类别数不同。AlexNet 是已预训练好的图像通用识别模型, 使用模型迁移方法需先去掉 AlexNet 网络的最后 3 层, 保留 AlexNet 剩余部分的结构和参数, 然后在后面添加一个全连接层, 全连接层的神经元个数为故障组合的类别数(若是单故障则神经元个数改为 12 个), 然后再添加一个 Softmaxlayer 层和 Classification layer 层。在训练网络时, 求解器采用 Adam 优化算法, 初始学习率为 0.000 02, 训练次数为 1 000 次, 小批量中的样本数为 16, 最大迭代数为 1 000 次。




图 8 双测点深度学习训练样本准确率曲线和学习损失曲线

Figure 8. Double measuring points deep learning training sample accuracy curve and learning loss curve

图 8 为被测电路单故障、双故障、单双混合故障 3 种不同组合的训练样本准确率曲线和故障损失曲线。由图 8 可知, 单故障的学习曲线处于准确率曲线的最上端, 其损失曲线处于最下端, 斜率高于双故障和混合故障, 双故障斜率其次, 混合故障的学习曲线和损失曲线的斜率最低。

#### 3.3.2 AlexNet 模型特征可视化

在 AlexNet 模型中每一层以前一层提取的特征作为输入并进行卷积及其他特定形式的运算, 可得到更高级的特征。

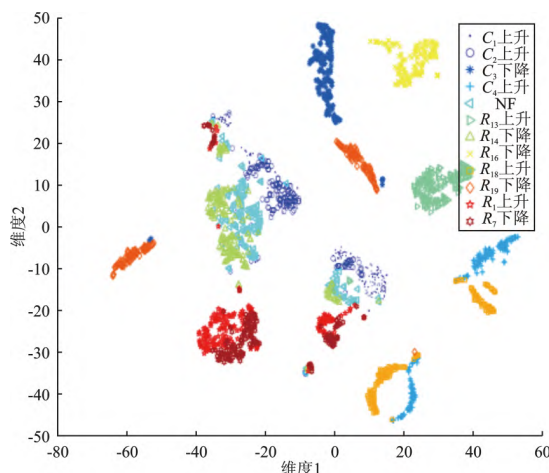


图 9 双测点单故障原始数据特征可视化

Figure 9. Double measuring points - single fault original data feature visualization

为直观展示 AlexNet 模型典型层的特征学习的特点, 采用 T-SNE (T-Distributed Stochastic Neighbor Embedding) 特征可视化技术, 将高维特征映射到二维空间。本文选取二级四运放双二阶低通滤波器的单故障组合进行特征可视化, 观察二级四运放低通滤波器单故障原始故障数据以及 AlexNet 中两层的特征可视化分布情况。




图 10 双测点单故障 AlexNet 第 2 层特征可视化

Figure 10. Visualization of AlexNet's second layer features with double measuring points - single fault


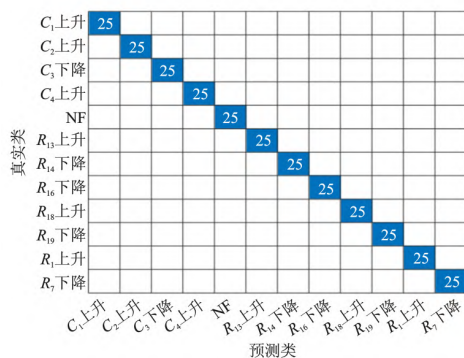
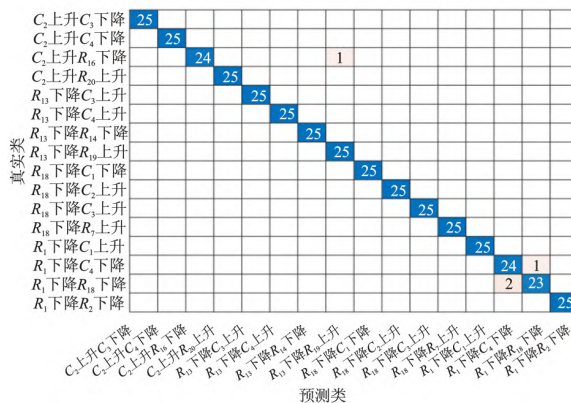


图 11 双测点单故障 AlexNet 第 8 层特征可视化


Figure 11. Visualization of AlexNet's eighth layer feature with double measuring points – single fault



(a)



(b)



(c)

图 12 双测点深度学习混淆矩阵

(a) 单故障 (b) 双故障 (c) 混合故障

Figure 12. Double measuring points deep learning confusion matrix

(a) Single fault (b) Double fault (c) Mixed fault



图 12 为被测电路单故障、双故障、混合故障深度学习的混淆矩阵。通过实验得到单故障的准确率为 100%, 双故障的准确率为 99.5% (双故障只有在  $C_2$  上升  $R_{16}$  下降、 $R_1$  下降  $C_4$  下降、 $R_1$  下降  $R_{18}$  下降这 3 类故障识别时判断有误) 混合故障的准确率为 99% (混合故障只有在  $C_2$  上升  $C_3$  下降、 $C_2$  上升  $R_{16}$  下降、 $R_1$  下降  $C_1$  上升、 $R_1$  下降  $C_4$  下降、 $R_1$  下降  $R_{18}$  下降、 $R_7$  下降这 6 类故障识别时判断有误)。

为区别双测点和单测点的故障诊断精度的差

异, 本文还对比了二级四运放双二阶低通滤波电路 + 单测点 + CEEMDAN 分解 + 伪彩色 + AlexNet 网络模型故障诊断实验。实验进行了单测点的单故障、双故障和混合故障 3 种组合的诊断识别。按照故障电路特征信息采集方法将二级四运放双二阶低通滤波电路设置相应故障, 从最后一级 Output<sub>1</sub> 提取故障信号, 把故障信号进行 CEEMDAN 分解、伪彩色出图、ALEXNET 网络模型识别, 最后通过实验得到混淆矩阵, 如图 13 所示。

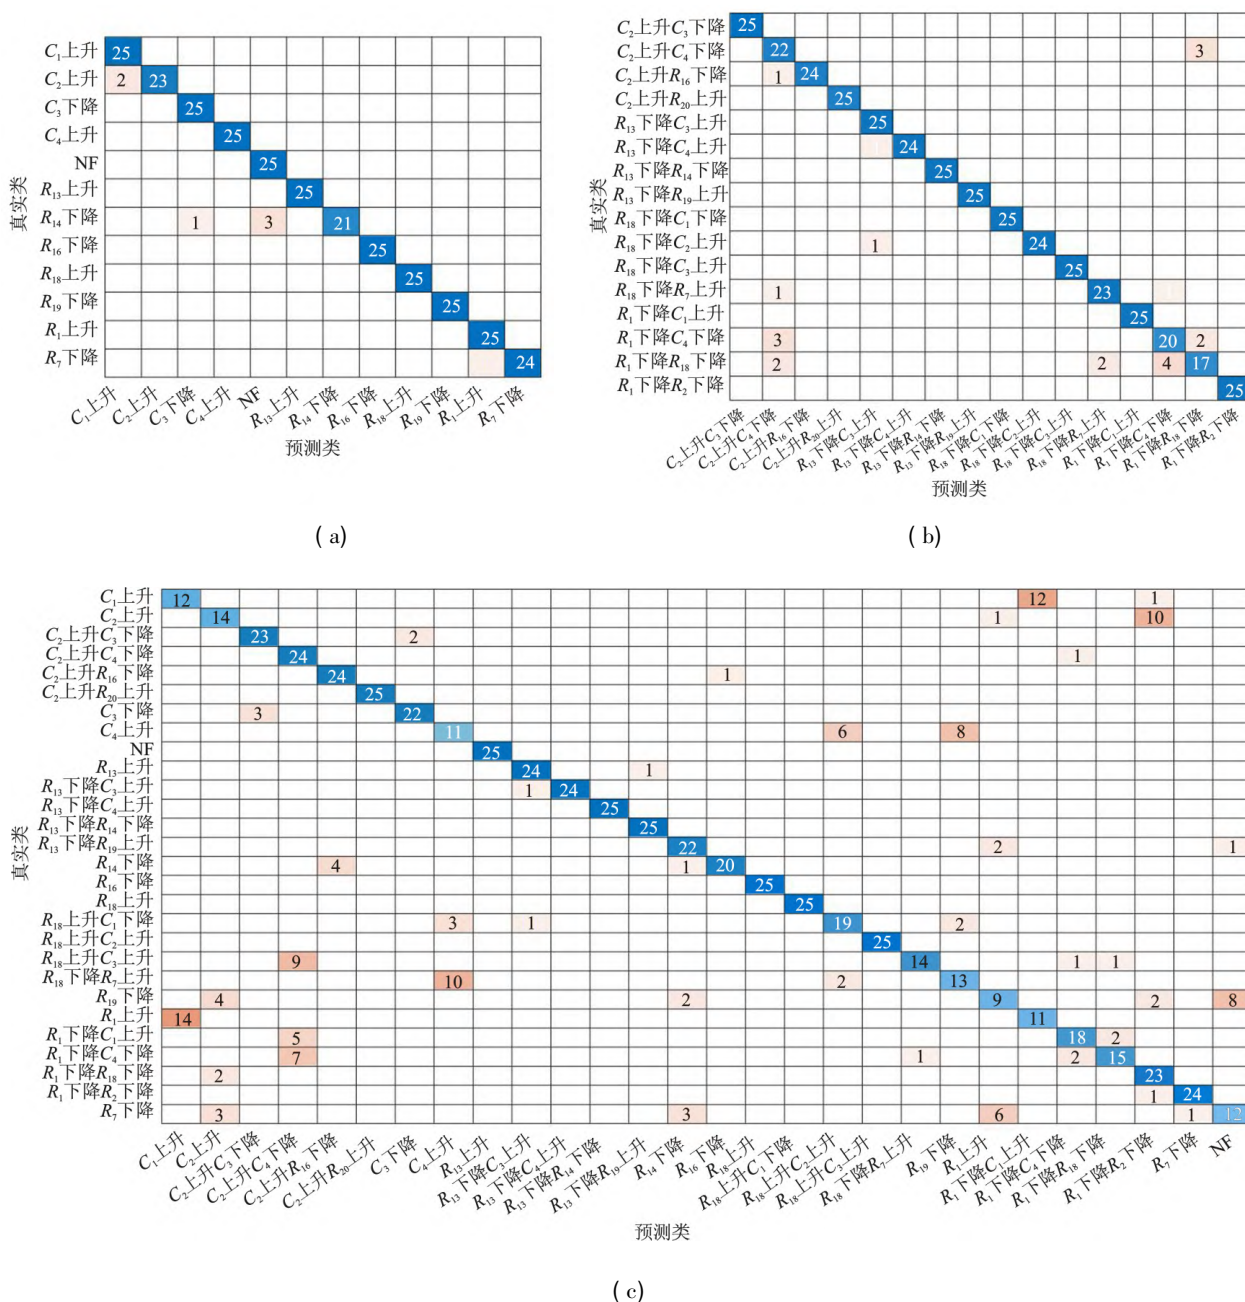


图 13 单测点 + CEEMDAN 分解 + 伪彩色 + AlexNet 网络模型

(a) 单故障 (b) 双故障 (c) 混合故障

Figure 13. Single measuring point + CEEMDAN decomposition + pseudo-color + AlexNet network model

(a) Single fault (b) Double fault (c) Mixed fault

通过对比图 12 和图 13 可知,单测点方案的单故障准确率为 97.67% ( $C_2$  上升、 $R_{14}$  下降、 $R_7$  下降这 3 类识别有误),双故障准确率能达到 94.75% ( $C_2$  上升  $C_4$  下降、 $C_2$  上升  $R_{16}$  下降、 $R_{13}$  下降  $C_4$  上升、 $R_{18}$  上升  $C_2$  上升、 $R_{18}$  下降  $R_7$  上升、 $R_1$  下降  $C_4$  下降、 $R_1$  下降  $R_{18}$  下降这 7 类识别时有误),混合故障的准确率下降到 79% (单测点混合故障只有  $C_2$  上升  $R_{20}$  上升、 $R_{13}$  上升、 $R_{13}$  下降  $R_{14}$  下降、 $R_{13}$  下降  $R_{19}$  上升、 $R_{18}$  上升、 $R_{18}$  上升  $C_1$  下降、 $R_{18}$  下降  $C_3$  上升这 7 类故障能正确识别)。因为该方案只有单测点,导致测点记录的数据无法充分表达故障特征信息,在双故障和混合故障中限制了 AlexNet 的分类能力,相比于双测点的结果具有一定差距。

通过实验单测点 + CEEMDAN 分解 + 伪彩色 + AlexNet 与双测点 + CEEMDAN 分解 + 伪彩色 + AlexNet 的实验结果进行相应对比,单故障组合中单测点方案的识别率为 97.67%,双测点方案的识别率为 100%。双故障组合中双测点方案的平均正确率高达 99.5%,而单测点方案平均正确率只有 94.75%。其中,单测点双故障中  $R_1$  下降  $R_{18}$  下降的正确率为 68%, $R_1$  下降  $C_4$  下降的正确率为 80%,明显低于双侧点方案对应的正确率。混合故障组合中单测点方案平均正确率只有 79%, $C_1$  上升、 $C_2$  上升、NF、 $C_4$  上升、 $R_{18}$  下降  $R_7$  上升、 $R_{19}$  下降、 $R_1$  上升、 $R_1$  下降  $C_1$  上升这几类故障的识别率都低于 60%,双测点方案的混合故障平均正确率依旧能保持到 99%,各个故障类型的正确率都能保持较高水平。由此证明双测点方案比单测点方案效果更优,双测点组合故障样本数据提高了表征复杂模拟电路整个故障状态的能力,即双测点 + CEEMAND 分解 + 伪彩色 + AlexNet 深度学习的方法对双故障和混合故障具有较高的正确率,双侧点方案对复杂的模拟电路进行故障识别具有高实用性和高诊断精度。

### 3.3.4 与其他识别方法比较

现行研究集中在简单的模拟电路,例如 Sallen-key 低通滤波器、三运放的低通滤波器,而超过 3 个运放的滤波器则称为复杂模拟电路,例如四运放二阶高通滤波器、Leapfrog 跳蛙滤波器(五运放)、二级四运放双二阶低通滤波器,复杂的滤波器故障诊断研究较少。研究二级四运放双二阶低通滤波器也都只限于单故障或双故障。表 3 为各种模拟电路故障诊断方法识别结果比较。文献[8]采用将故障信号转换成语频谱再利用 VGG16 (Visual Geometry

Group16) 模型进行深度学习实现了对 Sallen-key 低通滤波器单故障识别,其准确率为 100%。文献[19]采用哈里斯鹰算法(Improved Harris Hawks Optimization, IHHO) + BP (Back propagaion) 神经网络对 Sallen-key 低通滤波器和三运放 CSTV 低通滤波电路的混合故障进行诊断,诊断识别率分别达到了 95.77% 和 94.85%。文献[5]采用粒子群算法(PSO)与粒子滤波算法(PF)融合 + 支持向量机(SVM)方法对 Sallen-key 低通滤波器和四运放二阶高通滤波器的单故障进行识别,识别率分别为 95.6% 和 94.4%。文献[20]采用极限学习机(Extreme Learning Machine, ELM)自编码器(Auto Encoder, AE)的特征表示能力,构建深度学习的方法对四运放二阶高通滤波器的单故障类别进行识别,识别率为 100%。文献[21]采用具有挤压和激励模块的多尺度自归一化卷积神经网络(Squeeze-and-Excitation and Multiscaled Convolutional Neural Network, SE-MSCNN)的双输入模型方法对 Leapfrog 跳蛙滤波器混合故障进行识别,识别率为 83.58%。文献[22]采用广义多核支持向量机(Generalized Multiple Kernel Learning-Support-Vector-Machine, GMKL-SVM) + 量子粒子群优化(Quantum-behaved Particle Swarm Optimization, QPSO)算法对 Leapfrog 跳蛙滤波器的双故障组合进行识别,识别率为 97.3%。文献[4]采用基于模糊 C 均值聚类(Fuzzy-C-Means, FCM) + 局部线性嵌入(Local Linear Embedding-LLE)方法对单故障类别进行识别,其识别率为 93.7%。文献[7]采用基于深度置信网络(Deep Belief Network, DBN) + 广义多核支持向量机(GMKL-SVM)方法对单故障类别进行识别,识别率为 98.13%。本文采用的单测点 + CEEMAND 分解 + 伪彩色 + AlexNet 深度学习诊断方法对于单故障的识别率为 97.67%,对双故障识别率为 94.75%,对混合故障的识别率为 79%。本文采用的双测点 + CEEMAND 分解 + 伪彩色 + AlexNet 深度学习诊断方法,单故障的识别率为 100%,对双故障识别率为 99.5%,对混合故障识别率为 99%,即本文单测点方案优于 FCM + LLE 方法。本文双测点方案识别准确率高于单测点方案,在所有方法中识别率最高,说明复杂模拟电路双测点的选择能够有效提高故障数据,表征整个故障电路故障状态的能力。本文所提双测点方案性能优于其他常见特征提取方法,对复杂模拟电路不同故障类型的识别率更高。

表 3 不同诊断方法识别结果比较  
Table 3. Comparison of recognition results of various diagnostic methods

故障诊断方法	电路	准确率		
		单故障 / %	双故障 / %	混合故障 / %
语频谱 + VGG16	Sallen - key 低通滤波器	100.00	-	-
IHHO + BP	Sallen - key 低通滤波器	-	-	95.77
IHHO + BP	三运放 CSTV 低通滤波电路	-	-	94.85
PSO + PF + SVM	Sallen - key 低通滤波器	95.60	-	-
PSO + PF + SVM	四运放二阶高通滤波器	94.40	-	-
ELM - AE	四运放二阶高通滤波器	100.00	-	-
SE - MSCNN	Leapfrog 电路(五运放)	-	-	83.58
GMKL - SVM + QPSO	Leapfrog 电路(五运放)	-	97.30	-
FCM + LIE	二级四运放双二阶低通滤波器	93.70	-	-
DBN + SVM	二级四运放双二阶低通滤波器	98.13	-	-
单测点 + CEEMDAN + 伪彩色 + AlexNet	二级四运放双二阶低通滤波器	97.67	94.75	79.00
双测点 + CEEMDAN + 伪彩色 + AlexNet	二级四运放双二阶低通滤波器	100.00	99.50	99.00

## 4 结束语

本文使用 SIMetrix - SIMPLIS 8.20 仿真软件对二级四运放双二阶低通滤波器采用双测点输出故障数据,将整理后数据经 CCEEMDAN 分解得到多尺度数据矩阵,将多尺度数据矩阵进行量化编码获得像素矩阵,再对像素矩阵进行伪彩色编码得到多尺度伪彩色图,最后将所得伪彩色图送入 AlexNet 深度学习算法中进行故障识别。通过实验验证双测点 + CEEMAND 分解 + 伪彩色 + AlexNet 深度学习诊断方法比单测点 + CEEMAND 分解 + 伪彩色 + AlexNet 深度学习诊断方法准确度高;双测点检测 + CEEMAND 分解 + 伪彩色 + AlexNet 深度学习诊断方法优于传统机器学习方法,在复杂模拟电路故障诊断方面效果良好,解决了复杂模拟电路“二级四运放双二阶低通滤波器”的故障传递性复杂以及故障信号判断识别困难问题。经实验验证,本文所提出的故障诊断方法的准确率高,效果明显,降低了测试门槛,测试效果较好,并且减少了人工成本。

## 参考文献

- [1] Binu D, Kariyappa B S. A survey on fault diagnosis of analog circuits: Taxonomy and state of the art [J]. International Journal of Electronics and Communications 2017 73(1): 68 - 83.
- [2] 熊建. 基于时频分析和复数域的模拟电路故障诊断研究[D]. 成都: 电子科技大学, 2017: 1 - 62.  
Xiong Jian. Research on fault diagnostic methods for analog circuits based on time - frequency analysis and complex field analysis [D]. Chengdu: University of Electronic Science and Technology of China 2017: 1 - 62.
- [3] 刘雪梅. 基于经验小波变换和残差网络的模拟电路故障诊断方法研究[D]. 成都: 电子科技大学, 2022: 1 - 74.  
Liu Xuemei. Research on fault diagnosis method of analog circuit based on empirical wavelet transform and residual Network [D]. Chengdu: University of Electronic Science and Technology of China 2022: 1 - 74.
- [4] 王月海, 吕晓雯, 程冉, 等. 基于 FCM - LLE 的模拟电路故障诊断[J]. 北方工业大学学报, 2020, 32(2): 85 - 89.  
Wang Yuexhai, Lü Xiaowen, Cheng Ran, et al. A FCM - LLE - based fault diagnosis algorithm for analog circuits [J]. Journal of North China University of Technology 2020 32(2): 85 - 89.
- [5] 王力, 贾欣雨. 基于 PSO - PF - SVM 的模拟电路故障诊断[J]. 江苏大学学报(自然科学版), 2023, 44(2): 221 - 228, 234.  
Wang Li, Jia Xinyu. Fault diagnosis of simulation circuit based on PSO - PF - SVM [J]. Journal of Jiangsu University (Natural Science Edition) 2023 44(2): 221 - 228, 234.
- [6] 刘沛霖, 刘美容, 何怡刚, 等. 基于改进的 VMD 和 SVM 的模拟电路故障诊断方法的研究[J]. 微电子学与计算机, 2022, 39(11): 85 - 94.  
Liu Peilin, Liu Meirong, He Yigang, et al. Research on fault diagnosis method of analog circuit based on improved VMD and SVM [J]. Microelectronics and Computers, 2022 39(11): 85 - 94.
- [7] 张朝龙, 何怡刚, 杜博伦. 基于 DBN 特征提取的模拟电路早期故障诊断方法[J]. 仪器仪表学报, 2019, 40(10): 112 - 119.  
Zhang Chaolong, He Yigang, Du Bolun. Analog circuit incipient fault diagnosis method based on DBN feature extraction [J]. Chinese Journal of Scientific Instrument, 2019, 40(10): 112 - 119.
- [8] 易灵芝, 肖伟红, 于文新, 等. 基于深度学习的模拟电路故障诊断算法[J]. 计算机工程与应用, 2018, 54(24): 143 - 148.  
Yi Lingzhi, Xiao Weihong, Yu Wenxin, et al. Fault diagnosis algorithm research [D]. Chengdu: University of Electronic Science and Technology of China 2022: 1 - 74.

- gorithm for analog circuits based on deep learning. [J]. Computer Engineering and Applications 2018 54(24): 143–148.
- [9] 傅晨琦, 季利鹏, 孙伟卿, 等. 基于深度残差网络的模拟电路软故障诊断方法[J]. 飞控与探测 2021 4(4): 74–81.  
Fu Chenqi, Ji Lipeng, Sun Weiqing, et al. Deep residual learning – based soft fault diagnosis method for analog circuits [J]. Flight Control and Detection 2021 4(4): 74–81.
- [10] 杜先君, 巩彬, 余萍, 等. 基于 CBAM – CNN 的模拟电路故障诊断[J]. 控制与决策 2022 37(10): 2609–2618.  
Du Xianjun, Gong Bin, Yu Ping, et al. CBAM – CNN based analog circuit fault diagnosis [J]. Control and Decision, 2022 37(10): 2609–2618.
- [11] 张逸, 欧杰宇, 金涛, 等. 基于特征图像组合与改进 ResNet – 18 的电能质量扰动识别方法[J]. 中国电机工程学报 2024 44(7): 2531–2544.  
Zhang Yi, Ou Jieyu, Jin Tao, et al. Power quality disturbance recognition method based on feature image combination and modified ResNet – 18 [J]. Proceedings of the CSEE 2024, 44(7): 2531–2544.
- [12] 侯思祖, 郭威, 王子奇, 等. 基于小波 AlexNet 网络的配电网故障区段定位方法[J]. 电测与仪表 2022 59(3): 46–57.  
Hou Sizu, Guo Wei, Wang Ziqi, et al. Fault segment location method for distribution network based on wavelet AlexNet network [J]. Electrical Measurement and Instrumentation, 2022 59(3): 46–57.
- [13] 张永超. 模拟电路的测点选择及故障诊断方法研究[D]. 北京: 北京化工大学 2022: 3–5.  
Zhang Yongchao. Research on test point selection and fault diagnosis method of analog circuit [D]. Beijing: Beijing University of Chemical Technology 2022: 3–5.
- [14] 潘强, 孙必伟. 模拟电路故障诊断中的特征信息提取[J]. 电子科技 2013 26(8): 116–119.  
Pan Qiang, Sun Biwei. Feature information extraction in fault diagnosis of analog circuits [J]. Electronic Science and Technology 2013 26(8): 116–119.
- [15] Torres M E, Colominas M A, Schlotthauer G, et al. A complete ensemble empirical mode decomposition with adaptive noise [C]. Prague: IEEE International Conference on Acous-
- tics Speech and Signal Processing 2011: 4144–4147.
- [16] 李瑞, 范玉刚. 基于 CEEMDAN 多尺度排列熵和 SO – RELM 的高压隔膜泵单向阀故障诊断[J]. 振动与冲击, 2023 42(5): 127–135.  
Li Rui, Fan Yugang. Fault diagnosis of one – way valve of high – pressure diaphragm pump based on CEEMDAN multi – scale permutation entropy and SO – RELM [J]. Journal of Vibration and Shock 2023 42(5): 127–135.
- [17] 周小波, 邹任玲, 卢旭华, 等. 基于人工神经网络的表面肌电信号分类器研究进展[J]. 电子科技 2021 34(2): 62–67.  
Zhou Xiaobo, Zou Renling, Lu Xuhua, et al. Research progress of surface electromyography signal classifier based on artificial neural network [J]. Electronic Science and Technology 2021 34(2): 62–67.
- [18] 陈军锋, 王雪, 张效天. 非侵入式负荷识别边缘计算颜色编码研究[J]. 仪器仪表学报 2020 41(9): 12–19.  
Chen Junfeng, Wang Xue, Zhang Xiaotian. Non – intrusive load recognition using color encoding in edge computing [J]. Chinese Journal of Scientific Instrument 2020 41(9): 12–19.
- [19] 王力, 张露露. 基于 IHHO – BP 神经网络的模拟电路故障诊断[J]. 电子测量与仪器学报 2024 38(5): 238–248.  
Wang Li, Zhang Lulu. Fault diagnosis of analog circuit based on IHHO – BP neural network [J]. Journal of Electronic Measurement and Instrumentation 2024 38(5): 238–248.
- [20] 颜学龙, 马润平. 基于深度极限学习机的模拟电路故障诊断[J]. 计算机工程与科学 2019 41(11): 1911–1918.  
Yan Xuelong, Ma Runping. Fault diagnosis of analog circuits based on deep extreme learning machine [J]. Computer Engineering and Science 2019 41(11): 1911–1918.
- [21] Yang J L, Gao T Y, Jiang S D. A dual – input fault diagnosis model based on SE – MSCNN for analog circuits [J]. Applied Intelligence 2022 53(6): 128–136.
- [22] 张朝龙, 何怡刚, 袁莉芬, 等. 基于 GMKL – SVM 的模拟电路故障诊断方法[J]. 仪器仪表学报 2016 37(9): 1989–1995.  
Zhang Chaolong, He Yigang, Yuan Lifan, et al. Analog circuit fault diagnosis based on GMKL – SVM method [J]. Chinese Journal of Scientific Instrument 2016 37(9): 1989–1995.